

Prédiction de la résistance à la ciprofloxacine chez *E. coli* : phénotypage non supervisé et prédiction supervisée

DU Bioinformatique, UM6SS

12 septembre 2026

Table des matières

1	Objectif	1
2	Jeu de données	1
3	Travail demandé	3
3.1	1. Prétraitement	3
3.2	2. Apprentissage non supervisé (phynotype)	3
3.3	3. Apprentissage supervisé (funcml)	3
3.4	4. Question de lecture croisée	3
3.5	5. Hypothèses de travail à discuter	3
4	Garde-fous méthodologiques (évalués)	4
5	Livrables	4
6	Installation	4

1 Objectif

Ce projet vous demande de reproduire, sur un jeu de données réel d'isolats d'*E. coli*, la démarche à deux volets présentée en cours : une analyse **non supervisée** (phénotypage, package **phynotype**) et une analyse **supervisée** (prédiction de la résistance, package **funcml**), puis de croiser les deux résultats.

Question biologique : peut-on prédire la résistance à la **ciprofloxacine** (un antibiotique critique de première ligne pour les infections urinaires et bactériémies à *E. coli*) à partir de caractéristiques d'assemblage génomique, de métadonnées de collecte et de la co-résistance à sept autres antibiotiques ?

Vous devez produire un document reproductible (Quarto ou R Markdown) qui exécute l'ensemble de l'analyse de bout en bout, du chargement des données brutes jusqu'à l'interprétation finale.

2 Jeu de données

Fichier : `data/ecoli_amr_isolate_v2.csv` (701 isolats).

Il a été construit à partir de deux sources brutes (`data/raw/ecoli_amr_raw.csv` et `data/raw/ecoli_metadata_raw.csv`, extraites de la base BV-BRC) par le script `data/build_clean_data.R` : un échantillon de 700 isolats d'*E. coli* pour lesquels au moins 3 antibiotiques ont été testés et dont le statut ciprofloxacine est connu. Une ligne = un isolat. Les colonnes se répartissent en trois familles :

— **caractéristiques d'assemblage génomique** : `genome_length`, `gc_content`, `contigs`, `mlst`

- **métadonnées de collecte** : `isolation_country`, `host_name`, `host_group`, `collection_year`, `isolation_source`, `genome_quality`
- **phénotypes de résistance (AST)** pour 8 antibiotiques, dont la cible `ciprofloxacin` : `ampicillin`, `cefotaxime`, `ceftazidime`, `ciprofloxacin`, `gentamicin`, `meropenem`, `pip_taz` (pipéracilline/tazobactam), `sxt` (triméthoprim/sulfaméthoxazole), chacune valant `Resistant`, `Susceptible`, `Intermediate` ou `NA` (antibiotique non testé pour cet isolat).

Détail de chaque variable :

Variable	Famille	Type	Description
<code>genome_id</code>	identifiant	caractère	identifiant unique de l'isolat
<code>genome_length</code>	assemblage	numérique	longueur totale de l'assemblage (pb)
<code>gc_content</code>	assemblage	numérique	pourcentage de GC du génome
<code>contigs</code>	assemblage	numérique	nombre de contigs de l'assemblage
<code>mlst</code>	assemblage	catégorielle	type de séquence multilocus (lignée)
<code>isolation_country</code>	métadonnées	catégorielle	pays de collecte de l'isolat
<code>host_name</code>	métadonnées	catégorielle	hôte d'origine (espèce)
<code>host_group</code>	métadonnées	catégorielle	regroupement de l'hôte (humain / animal / autre)
<code>collection_year</code>	métadonnées	numérique	année de collecte
<code>isolation_source</code>	métadonnées	catégorielle	source du prélèvement (urine, sang, etc.)
<code>genome_quality</code>	métadonnées	catégorielle	indicateur de qualité de l'assemblage
<code>ampicillin</code>	AST	catégorielle	statut de résistance à l'ampicilline
<code>cefotaxime</code>	AST	catégorielle	statut de résistance au céfotaxime
<code>ceftazidime</code>	AST	catégorielle	statut de résistance à la ceftazidime
<code>ciprofloxacin</code>	AST	catégorielle	statut de résistance à la ciprofloxacin (cible)
<code>gentamicin</code>	AST	catégorielle	statut de résistance à la gentamicine
<code>meropenem</code>	AST	catégorielle	statut de résistance au méropénème
<code>pip_taz</code>	AST	catégorielle	statut de résistance à la pipéracilline/tazobactam
<code>sxt</code>	AST	catégorielle	statut de résistance au triméthoprim/sulfaméthoxazole

Chaque variable AST vaut `Resistant`, `Susceptible`, `Intermediate` ou `NA` (antibiotique non testé pour cet isolat).

Lisez le fichier `data/build_clean_data.R` avant de commencer : il documente précisément la provenance et la logique d'échantillonnage des données, ce qui vous aidera à justifier vos choix de prétraitement.

3 Travail demandé

3.1 1. Prétraitement

1. Construisez la cible binaire `cipro_R` (résistant / sensible) à partir de `ciprofloxacine`, en ne conservant que les isolats dont le statut est sans ambiguïté (`Resistant` ou `Susceptible`).
2. Traitez soigneusement **deux types de valeurs manquantes de nature différente** : (i) un résultat AST absent signifie “non testé”, un statut cliniquement réel, à coder comme catégorie explicite, jamais à imputer ; (ii) une métadonnée de collecte absente (p. ex. `isolation_country`) est une donnée manquante au sens classique, légitimement imputable. Pour ce second cas, utilisez le package `missknn` (imputation par k plus proches voisins masqués) plutôt qu’une catégorie “Inconnu” générique, et justifiez ce choix en une ou deux phrases.
3. Regroupez les modalités rares (pays, hôte) pour éviter des niveaux absents d’un pli de validation croisée.
4. Rappelez la prévalence de la résistance et discutez de son implication sur le choix des métriques (déséquilibre de classes).

3.2 2. Apprentissage non supervisé (phynotype)

1. Préparez les données mixtes (numériques + catégorielles) **sans** utiliser la cible `cipro_R`.
2. Ajustez une solution de clustering et validez-la (indices internes + stabilité bootstrap) ; justifiez le choix du nombre de groupes k .
3. Explorez la solution retenue (profils, tailles, biplot) et interprétez au moins une méthode d’interprétabilité (importance par permutation, ceteris paribus ou LIME).
4. Croisez a posteriori le phénotype obtenu avec `cipro_R` : les groupes trouvés sont-ils associés à la résistance, alors qu’ils ont été construits sans jamais l’utiliser ?

3.3 3. Apprentissage supervisé (`funcml`)

1. Séparez un jeu de test (environ 25 %), mis de côté une seule fois, avant tout réglage ou sélection de modèle.
2. Comparez, par validation croisée sur le jeu d’entraînement uniquement, exactement les sept apprenants suivants, tous enregistrés directement dans `funcml::compare()` : `glm`, `rpart`, `ranger`, `fastgbm`, `densemle`, `knn`, `e1071_svm` (SVM). Rappelez, en plus de l’AUC et du score de Brier, l’exactitude (`accuracy`) et le F1-score, et discutez ce que ces deux dernières métriques ajoutent (ou pas) compte tenu du déséquilibre de classes constaté en partie 1.
3. Sélectionnez le meilleur modèle sur AUC validée croisée (en lisant l’intervalle, pas seulement la moyenne), réglez ses hyperparamètres si pertinent, puis ajustez le modèle final sur le jeu d’entraînement complet.
4. Vérifiez la robustesse du résultat par une validation croisée **groupée** par pays de collecte (`group_cv()`), et comparez-la à la validation croisée standard : un écart important est le signe d’un effet de collecte plutôt que d’un effet biologique.
5. Appliquez le modèle final au jeu de test et évaluez : courbe ROC + AUC, score de Brier, courbe de calibration, et au moins une méthode d’interprétabilité globale (importance par permutation ou SHAP global) **et** une méthode locale (SHAP local sur une observation, ou courbe ceteris paribus).
6. Incluez le phénotype trouvé en partie 2 comme variable candidate du modèle supervisé.

3.4 4. Question de lecture croisée

Le phénotype non supervisé contribue-t-il réellement au modèle supervisé ? Justifiez à partir de l’importance de variable / SHAP.

3.5 5. Hypothèses de travail à discuter

Formulez votre propre lecture (2 à 4 phrases chacune, appuyées sur vos résultats) des trois pistes suivantes :

1. **H1, co-résistance** : la résistance aux autres antibiotiques (bêta-lactamines, aminosides) est-elle associée à la résistance ciprofloxacine, et cette association est-elle plausible biologiquement (éléments génétiques mobiles partagés) ?
2. **H2, signal d'assemblage** : `genome_length/gc_content` apportent-ils un signal, et si oui, de quelle nature (direct ou indirect) ?
3. **H3, confusion géographique/hôte** : la répartition inégale du pays ou de l'hôte entre classes traduit-elle un effet de collecte, un effet biologique réel (diffusion d'un clone résistant), ou les deux ?

4 Garde-fous méthodologiques (évalués)

Votre rapport doit montrer explicitement que vous avez évité les cinq pièges de l'apprentissage automatique en génomique vus en Partie 1 du cours :

1. **Décalage de distribution** : le jeu de test est-il représentatif ?
2. **Dépendance entre exemples** : la validation groupée par pays a-t-elle été utilisée à bon escient ?
3. **Confusion** : la structure de population (pays, hôte) a-t-elle été discutée comme facteur de confusion possible ?
4. **Fuite de données** : tout prétraitement (imputation, sélection de variables) est-il ajusté uniquement sur les données d'entraînement, à l'intérieur de la boucle de validation croisée ?
5. **Déséquilibre de classes** : les métriques choisies (AUC, Brier, calibration, exactitude, F1) sont-elles adaptées à la prévalence observée ?

5 Livrables

- Un document Quarto (`.qmd`) reproductible, avec tout le code exécuté et ses sorties (tableaux, graphiques).
- Un export PDF ou HTML du document rendu.
- Une conclusion écrite (une demi-page environ) répondant explicitement aux hypothèses H1–H3 et à la question de lecture croisée (partie 4), en rappelant les limites de l'analyse (pas de preuve causale, pas de validation externe).

6 Installation

Tous les packages du projet sont installés depuis leur version de développement sur GitHub, via **pak** :

```
install.packages("pak")
pak::pak(c(
  "ielbadisy/funcml",
  "ielbadisy/missknn",
  "ielbadisy/phynotype"
))
```

`fastgbm` et `densem1p` sont des dépendances de `funcml` (apprenants enregistrés directement dans le package) : ils sont installés automatiquement avec `funcml`, il n'est pas nécessaire de les installer ni de les charger séparément.